

広告効果におけるデータ分析

1. 概論

小林 弦矢

2023 年 4 月 14 日

本日の内容




- 広告効果分析のモチベーション
- データ分析のアプローチ
 - トップダウン型：マーケティング・ミックス分析
 - ボトムアップ型：アトリビューション分析
- マルチタッチモデル
- デジタルマーケティングにおける知見の紹介
- 最後に

広告効果分析のモチベーション

日本の媒体別広告費の推移



- インターネット広告は 2008 年以降常に増加傾向（2020 年：2 兆 2290 億円，2021 年：2 兆 7052 億円）
- マスコミ 4 媒体（新聞，雑誌，ラジオ，テレビ）は 2021 年を除いて 2015 年以降減少傾向（2020 年：2 兆 2536 億円，2021 年：2 兆 4538 億円）




日本の媒体別広告費の推移 [1, 2]

目的別利用メディア




- 40代までは「いち早く世の中のできごとや動きを知る」ためにインターネットを使用する人が多い
- 全年代で「世の中のできごとや動きについて信頼できる情報を得る」にはテレビが優勢
- 全年代で「趣味・娯楽に関する情報を得る」にはインターネットが優勢



目的別利用メディア [1]

購買行動のための情報源



購入前に消費者が商品を見たチャンネル [3]

- 世界 51 カ国, 18,430 人の消費者を対象とした調査
- オンラインチャンネルもオフラインチャンネルも両方とも商品認知のきっかけとなる（それぞれ 59%, 52%）
 - オンラインチャンネルのうち、オンラインショップで 30%、オンライン広告で（15%）
 - 実店舗で 22%

ソーシャルメディア系サービスの利用



	全年代(N=1,500)	10代(N=141)	20代(N=215)	30代(N=247)	40代(N=324)	50代(N=297)	60代(N=276)	男性(N=759)	女性(N=741)
LINE	92.5%	92.2%	98.1%	96.0%	96.6%	90.2%	82.6%	89.7%	95.3%
Twitter	46.2%	67.4%	78.6%	57.9%	44.8%	34.3%	14.1%	46.5%	45.9%
Facebook	32.6%	13.5%	35.3%	45.7%	41.4%	31.0%	19.9%	34.1%	31.0%
Instagram	48.5%	72.3%	78.6%	57.1%	50.3%	38.7%	13.4%	42.3%	54.8%
mixi	2.1%	1.4%	3.3%	3.6%	1.9%	2.4%	0.4%	3.0%	1.2%
GREE	0.8%	0.7%	1.9%	1.6%	0.6%	0.3%	0.0%	1.3%	0.3%
Mobage	2.7%	4.3%	5.1%	2.8%	3.7%	0.7%	0.7%	3.4%	1.9%
Snapchat	2.2%	4.3%	5.1%	1.6%	1.9%	1.7%	0.4%	1.3%	3.1%
TikTok	25.1%	62.4%	46.5%	23.5%	18.8%	15.2%	8.7%	22.3%	27.9%
YouTube	87.9%	97.2%	97.7%	96.8%	93.2%	82.5%	67.0%	87.9%	87.9%
ニコニコ動画	15.3%	19.1%	28.8%	19.0%	12.7%	10.4%	7.6%	18.1%	12.4%

主なソーシャルメディア系サービス/アプリ等の利用率（全年代・年代別） [4]

- LINE と YouTube は全年代で高い利用率
- 他は年代によって利用率が異なる
 - Facebook は 30 代～40 代の利用率が他の年代に比べて高い
 - Instagram, TikTok は 10 代～20 代の利用率が他の年代に比べて高い

広告効果分析のモチベーション



- より複雑になってきているマーケティング環境の中で、前述のような年々増大する広告費に対するアカウンタビリティ果たしたい
 - マーケティング・ミックス
 - 技術環境
 - カスタマージャーニー
- 広告の売上に対する貢献度を測定し、広告費を最適化することで企業価値の向上を目指す

データ分析のアプローチ

2つのアプローチ



- トップダウン型：マーケティング・ミックス分析
 - 売上などに対して広告費などのマーケティング変数がどのように影響を与えるかを測定し、予算配分の最適化を目指す
 - 集計されたデータに対して統計モデルを適用
- ボトムアップ型：アトリビューション分析
 - 消費者が購買に至るまでの過程における各接点（チャネル）に対し、それらの売上などに対する貢献度を配分・評価する
 - 各取引データを使用するためオンラインで完結する取引に対して有用
 - 購買が実店舗で実現する場合には適用が困難

マーケティング・ミックス分析

マーケティング・ミックス分析



- 集計された売上データに対し，統計モデルの枠組みでマーケティング変数がどのように影響を与えるかを推定
- メディア広告に焦点を当てたものはメディア・ミックス分析と呼ばれる（次回以降より詳しく紹介）
- とても簡単な例：

$$\begin{aligned} \text{売上} = & \text{定数} + \beta_1 \text{テレビ広告費}_t + \beta_2 \text{google 広告費} \\ & + \beta_3 \text{Facebook 広告費} + \beta_4 \text{祝日ダミー} + \text{ランダムな項} \end{aligned}$$

マーケティング・ミックスモデル (MMM)



■ より一般的には

$$Y = g(X; \theta) + \epsilon,$$

- Y : 被説明変数 (売上など, あるいはそれを変換したもの)
- X : 説明変数 (マーケティング変数など Y に影響を与え则认为らる変数, あるいはそれを変換したもの)
- $g(X; \theta)$: パラメータ θ を持つ X の関数
- ϵ : ランダムな誤差項
- 統計モデルを推定し, それに基づいて予測・シミュレーションを行う
 - 各マーケティング変数 (広告メディア) に対する ROI の評価
 - 予算配分の最適化
 - 関心のある数量の不確実性評価

線形回帰モデル



- MMM の一番簡単なスタート地点として線形回帰モデルが挙げられる

$$Y_t = \beta_0 + \beta_1 X_{1t} + \beta_2 X_{2t} + \cdots + \beta_K X_{Kt} + \epsilon_t, \quad t = 1, \dots, T,$$

- Y_t : 時点 t における被説明変数
- X_{kt} : 時点 t における k 番目の説明変数
- β_k : 回帰パラメータ ($k = 0, 1, \dots, K$)
- ϵ_t : 時点 t における誤差項
- 例: Y_t を週 t における売上, X_{kt} をメディア k に対する広告費用とすると

$$\log Y_t = \beta_0 + \beta_1 \log X_{1t} + \beta_2 \log X_{2t} + \cdots + \beta_K \log X_{Kt} + \epsilon_t$$

などとすることもできる

線形回帰モデルの限界



- 線形回帰モデルは最小二乗法などで簡単に推定できる
- 構造が単純すぎるためバイアスのある結果を生み出す可能性がある：
 - 線形性が制約的
 - 分散不均一性
 - 時系列データを使用する際に時系列構造を無視
 - 誤差分布の仮定：正規分布からの逸脱
- 一般的な拡張の方向性
 - 非線形回帰モデル：加法モデルなど
 - 回帰木モデル：XGBoost など
 - 時系列モデル：ARIMA モデル，状態空間モデルなど
 - 階層モデル


広告効果測定における問題



- 広告費が線形に売上に貢献するという仮定は非現実的
 - 過去の広告費の効果の
 - 過去の広告効果の蓄積と減衰
 - 一定のレベルに達すると追加的な広告支出が売上に貢献しなくなる（飽和）
- なども考慮することが望ましい
- メディアミックスモデルにおけるデザイン方法は次回以降より詳しく紹介

アトリビューション分析

購買までの過程

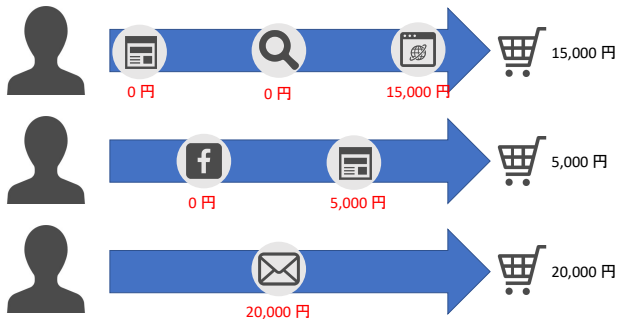


- 売上に対する各チャネルの貢献度をどのように評価するか
- 売上をチャネルに配分
- どのように配分するか？
 - ルールベース
 - 統計ベース

ラストタッチモデル



- 最も単純で広く使われているルールベースの方法
- 最後のチャンネルに売上をすべて配分
- 最初のチャンネルに売上をすべて配分する場合はファーストタッチ



ラストタッチモデル



- 解釈が単純：最終的な購買に至ったチャネルを特定
- 広告キャンペーンの効率性を素早く評価することができる
- 購買に至るまでの各ステップを完全に無視（チャネルが1つしかない場合には問題ない）
- 複数のステップ・チャネルを考慮するマルチタッチアトリビューション（MTA）を考慮する必要


減衰モデル



- 購買から遠くなるにつれて配分比を減衰させる

$$W_s = \frac{s(s+1)}{2}, \quad s = 1, \dots, S$$

- $S = 3$ ステップの場合：各ステップに 10%, 30%, 60% 配分




減衰モデル



- 購買に近いチャネルほど配分比が大きくなるため、素早く取引を成立させるマーケティングチャネルがより大きな配分を受ける
- 短期間のプロモーションにおいて有用と考えられる

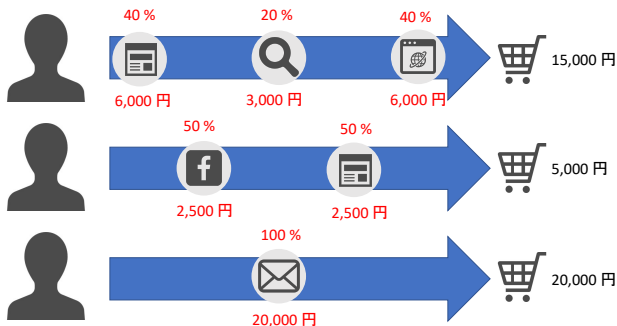
一様（線形）モデル

- 各接触が購買に対して同じ影響を持つと想定
- すべてのチャンネルが同じ配分を受ける



パレート（U字, ポジション）モデル

- 最初と最後のチャンネルが大きな配分（例：80%）を受ける
- 最初のインプレッションはユーザーを引きつけ、最後のインプレッションは購買に結びつけるという点で重要であるという考え方



統計ベースのアトリビューション分析



- 理想的なアトリビューション分析とは [5]
 - 購買に対する各チャネルの貢献度をフェアに評価する
 - データに基づいて貢献度評価を行う (data driven)
 - 解釈可能性が高い
- 統計モデルに基づいた方法は3つの点を同時に達成可能
- ここでは回帰モデルに関連する手法を紹介：
 - ドミナンス (dominance) 分析 [6, 7]
- これらの方法は各チャネルの因果効果を評価するものではなく、相対的な重要性 (relative importance) を評価するに留まる

ドミナンス分析

ドミナンス (dominance) 分析



- シャプレー値回帰 (Shapley value regression), Kruskal 分析, 増分 (incremental) R^2 分析などとも呼ばれる
- 回帰分析における決定係数 R^2 を説明変数のすべての組み合わせのもとで計算し, それぞれの説明変数の組み合わせに対して追加的にもう 1 つ説明変数を追加したときにどの程度 R^2 が増加するかに基づいて各説明変数の貢献度を評価
- R^2 に対する各説明変数のシャプレー値
- シャプレー値: 協力ゲームにおいて, 報酬を各プレイヤーの貢献度に応じて配分する方法の 1 つ

決定係数 R^2



- 次の重回帰モデルを考える

$$Y_i = \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_K X_{Ki} + \epsilon_i, \quad i = 1, \dots, N$$

- 被説明変数 Y と各説明変数 X_k は標準化してある（平均 0, 分散 1）
- X_{ki} はチャンネル k に対するユーザー i の暴露の履歴を表す
- R^2 は Y の変動のうち回帰モデルで説明できる割合を表す：

$$R^2 = 1 - \frac{\sum_{i=1}^N (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^N (Y_i - \bar{Y})^2}$$

ここで

- \bar{Y} : Y の標本平均
- $\hat{Y}_i = \hat{\beta}_1 X_{1i} + \cdots + \hat{\beta}_K X_{Ki}$: 当てはめ値
- $\hat{\beta}_k$: β_k の推定値 ($k = 1, \dots, K$)
- 説明変数をモデルに追加すると, R^2 は単調増加する（減らない）

R^2 の分解



- 説明変数の間に相関がない場合には次が成立

$$R^2 = \sum_{k=1}^K \text{cor}(Y, X_k)^2 = \sum_{k=1}^K \beta_k^2$$

- $\text{cor}(Y, X_k)$: Y と X_k の相関係数
- この場合、回帰係数を各説明変数の貢献度として解釈することができる
- 説明変数の間に相関がないという仮定は複数チャネルにおける広告効果のコンテキストでは非現実的であり、この方法は使用することはできない

ドミナンス分析のアルゴリズム



- 1 R^2 をすべての説明変数の組み合わせ ($2^K - 1$ 個のモデル) について計算する
- 2 各説明変数 X_k について ($k = 1, \dots, K$):
 - X_k 以外の説明変数が h 個含まれるモデルの R^2 と, それに X_k を加えたときの R^2 の増分を計算し, $K-1$ 通りの R^2 の増分の平均 ($C_{X_k}^h$) を計算する
 - 上記を $h = 0, \dots, K-1$ の場合で計算して平均を取る:

$$\phi_{X_k} = \frac{1}{K} \sum_{h=0}^{K-1} C_{X_k}^h$$

- 3 R^2 は次のように分解される

$$R^2 = \sum_{k=1}^K \phi_{X_k}$$

説明変数の組み合わせの例



- X_1, X_2, X_3 の $K = 3$ つの説明変数があるとする
- 以下の $2^3 - 1 = 7$ 通りの組み合わせについてそれぞれ R^2 を計算する
 - 説明変数が 1 つ: $\{X_1\}, \{X_2\}, \{X_3\}$
 - 説明変数が 2 つ: $\{X_1, X_2\}, \{X_1, X_3\}, \{X_2, X_3\}$
 - 説明変数が 3 つ: $\{X_1, X_2, X_3\}$
- $R_{Y, \{\cdot\}}^2$ を Y を説明変数の集合 $\{\cdot\}$ に回帰したときの R^2 とする,
- X_1 の貢献は

$$\phi_{X_1} = \frac{1}{3}(C_{X_1}^0 + C_{X_1}^1 + C_{X_1}^2)$$

- $h = 0: C_{X_1}^0 = R_{Y, \{X_1\}}^2$
- $h = 1:$

$$C_{X_1}^1 = \frac{1}{2} \left((R_{Y, \{X_1, X_2\}}^2 - R_{Y, \{X_2\}}^2) + (R_{Y, \{X_1, X_3\}}^2 - R_{Y, \{X_3\}}^2) \right)$$

- $h = 2:$

$$C_{X_1}^2 = R_{Y, \{X_1, X_2, X_3\}}^2 - R_{Y, \{X_2, X_3\}}^2$$

ドミナンス



- 説明変数 X_k と $X_{k'}$ 以外のすべての説明変数の組み合わせにおいて、 X_k だけを追加した場合の R^2 の増分が、 $X_{k'}$ だけを追加した場合の R^2 の増分よりも大きい場合、 X_k が $X_{k'}$ を完全にドミネート (complete dominance) するという
- すべての h (モデルに含まれる X_k あるいは $X_{k'}$ 以外の説明変数の数) について $C_{X_k}^h \geq C_{X_{k'}}^h$ のとき、 X_k が $X_{k'}$ を条件付きでドミネート (conditional dominance) するという
- $\phi_{X_k} \geq \phi_{X_{k'}}$ のとき X_k が $X_{k'}$ を一般的にドミネート (general dominance) するという
- Complete dominance \Rightarrow conditional & general dominance

デジタルマーケティングにおける最近の知見 [8]

オンライン広告の効率性



- 一般的にオンライン広告は正のリターンを生む
- そのマグニチュードは製品カテゴリ，消費者のセグメント，広告フォーマットに依存して異なる
- クロスメディアは正のシナジー効果を生む
- どの順番でそれぞれのメディアに暴露すると最適なシナジー効果を生むかは製品や消費者のタイプに依存する

オンライン広告の力学



- 広告に対する高い関与（クリックや感情的な関与）の度合いはオンライン広告を効率的なものにさせる
- 単なる広告暴露に対する効果
 - ユーザーが注意を払っていないときほど好意的な態度につながり、潜在記憶につながる（顕在記憶には効果なし）
 - ユーザーのメインタスクが複雑であり、焦点を当てているコンテンツに広告が視覚的・空間的に近いときほど暴露に対する効果が低くなる（広告を能動的に無視しようとするため広告に対する評価が悪くなる：distractor devaluation effect）

オンライン広告の創造的な要素



- 注意を引きつけようとする広告は諸刃の剣
 - 大きくてリッチな広告は認知と再生を強める
 - 押し付けがましくて邪魔と感じられてしまう
- 感情に対する訴求は重要
 - ポジティブな感情
 - ユーモアなどのより複雑な感情
- 同じ広告を見せ続けるのは再生力とクリックを増やす一方で、悪い効果もある
- コンテンツにバリエーションをもたせることでこの悪い効果を軽減させることができる
 - ホストウェブサイトがごちゃごちゃしていなくて広告コンテンツと関連性がないときに有効である可能性

オンライン広告におけるコンテキストの役割



Nospare

- オンライン広告の効果はコンテキストに依存，ポジションやゴールなどのコンテキストに沿った広告のほうが効果的
- 最近ではユーザーの地理的な位置が注目：モバイル広告
 - ユーザーの現在の位置に合った広告のほうがより購買につながる
 - 同じ位置にいるユーザーは広告に同じように反応する傾向がある

オンラインパーソナライゼーション



- パーソナライゼーションの方法
 - 消費者の過去の行動に基づく：リターゲティング広告
 - 現在の行動に基づく：コンテンツ連動型広告
 - 消費者本人の情報に基づく：パーソナライズ化したメールなど
 - 位置に基づく：モバイル広告
- パーソナライゼーションは広告主の収益にとっても消費者にとっても正の効果をもたらす
- ただし消費者が購買意思決定に近づくほどその効果が小さくなる
 - 情報の取得がゴールのときに大きなインパクトを与える
- その効果は視認性やコンテンツなどの内容にも依存して決まる
- 一方でプライバシーに対する心配も

検索広告



- 消費者のキーワードによって情報と広告が同時に決まる
- キーワード
 - より一般的ではなく、より具体的なキーワードのほうがクリックにつながりやすい
 - 広告主の名前を含むキーワードもクリックにつながりやすい
- ポジションと入札価格
 - 高いポジションのほうがクリックにつながりやすいが、コスト増大によって収益が減る可能性
 - コンバージョン率にポジションが正の効果を持つか負の効果を持つかは、研究結果が分かれる
 - 競合相手の行動にも依存する

まとめ

- 日本の広告費，オンライン利用の概観
- マーケティング・ミックス分析
- アトリビューション分析
 - ルールベース
 - 統計ベース：ドミナンス分析
- デジタルマーケティングに関する最近の知見

参考文献



- [1] 総務省『令和 4 年版 情報通信白書』
- [2] 電通『2021 年 日本の広告費』
- [3] KPMG (2017). 『「オンラインショッピングにおける消費者行動の実態」に関する調査結果について』 <https://kpmg.com/jp/ja/home/media/press-releases/2017/05/online-shopping-2017.html>
- [4] 総務省「令和 3 年度情報通信メディアの利用時間と情報行動に関する調査報告書」
- [5] Dalessandro, B., Sitelman, O., Perlich, C. & Provost, F. (2012). Cusally motivated attribution for online advertising. in: Proceedings of the Sixth International Workshop on Data Mining for Online Advertising and Internet Economy, ADKDD 2012.
- [6] Budescu, D. V. (1993). Dominance analysis: A new approach to the problem of relative importance of predictors in multiple regression. Psychological Bulletin, 114(3), 542 – -551.
- [7] Azen, R. and Budescu, D. V. (2003). The dominance analysis approach for comparing predictors in multiple regression. Psychological Methods, 8(2), 129 – -148.
- [8] Liu-Thompkins, Y. (2019). A decade of online advertising research: what we learned and what we need to know. Journal of Advertising, 48(1), 1–13.

Q & A



- Q: マーケティングミックスモデルで、変数として何を入れればいいのかはどうやって判断すればいいでしょうか？変数同士の交差を考慮したほうがいいというケースもあるのでしょうか？
A: マーケティング分析において被説明変数（売上など）に対する影響を与えるようなもの（広告費など）や、ドメイン知識に基づいてその他被説明変数に影響を与えられようもの（天候、地域、祝日、時期などの情報）を含めることができます。
- Q: 変数同士の交差を考慮したほうがいいというケースもあるのでしょうか？
A: ある説明変数が被説明変数に与える影響が他の説明変数の値にも依存すると考えられる場合には交差項（天候 × 祝日など）を含めることは有用であると考えられます。
- Q: 不確実性の評価としては、95%信頼区間を使うことが一般的なのでしょうか？
不確実性の対象によって信頼区間や予測区間などが使用されます。ベイズ推定では信用区間が使用されます。
- Q: 売上の場合、基本的にログを取ったほうがいいのでしょうか？ログを取るかどうかはどのように判断すればいいのでしょうか？
A: データの状況や目的に応じて対数を取るようになります。例えば、（売上・所得など）分布の右裾が長い場合に対数を取ると右裾を分布の中央に寄せることができます。また被説明変数も説明変数も対数スケールの線形モデルの場合、対応する回帰係数は弾力性の解釈になります。

Q & A



- Q：実際にモデリングする際は最初から高度な状態空間モデルや階層モデルを使えば良いのでしょうか？それとも簡単な線形モデルから試した方が良いでしょう？またより高度なモデルを試すかどうかの判断は基本的に汎化性能が十分な精度かどうかから判断するので問題ないでしょうか？
A：簡単な線形モデルから出発し、汎化性能やモデル診断などによって簡単なモデルに問題点が見つかった場合、それらを補うためにモデルを拡張していけばよい考えられます。
- Q：21 ページ，2 段目の配分はどのような計算式で求められるのでしょうか？
A： $S = 3$ ステップの場合ですので， $W_s = s(s+1)/2$ に $s = 1, 2, 3$ を代入すると $1 : 3 : 6$ という配分比が得られます
- A：アトリビューション分析の配分を決める際に、メディアの接触タイミングだけでなく、メディアがコンバージョンに与える影響力（いわゆるメディアパワーみたいなもの）を考慮の方が実態に近くなるケースもあると考えています。つまり各メディアへの配分比を（接触順の配分） \times （メディアパワーの比）という式で求めるイメージです。このメディアパワーを算出する際には、メディアミクシングモデルのような方法になると思っています。つまり、アトリビューション分析とメディアミクシングモデルの両方を使った分析になるのではないかと思います。このような手法は一般的だったりするのでしょうか？もしくは何か懸念点などあれば教えていただけないでしょうか。
Q：ご指摘の通り，2 つのアプローチの組み合わせはとても重要であると考えられます。メディアミックスとアトリビューションを組み合わせたとようなサービスは存在するようである一方で，論文ベースではそのような方法は確認できませんでした。このような場合においても data driven の手法を利用することが好ましいと考えられます。

Q & A



- Q：ドミナンス分析で R^2 ではなく AIC などでも同様の計算が可能かと思いますが、そういったバリエーションはあるのでしょうか？ P30 のような R^2 の分解が成り立たないのでしょうか？
 A：誤差 2 乗和の単調関数である指標には同様の分解が可能となります。例えば、疑似 R^2 ，AIC，Mallows' C_p が挙げられます (Azen, R.(2000). Inference for predictor comparisons: Dominance analysis and the distribution of R^2 differences. Unpublished doctoral dissertation, University of Illinois, Urbana-Champaign).
- Q：今回紹介されたドミナンス分析だと、決定係数の向上に寄与する変数、つまり回帰モデルの当てはまりのよさに寄与する変数を探す、という理解であっているのでしょうか。その場合目的変数への寄与とは違うものかと思うので、この結果をどうサービス分析に活かすのがイメージがわいていません。アトリビューション分析の重み付けに使うのでしょうか？
 ドミナンス分析では決定係数に対する貢献を各説明変数に配分し、その結果はアトリビューション分析での重み付けに利用できます。被説明変数の変動のうちモデルで説明できる部分に対する貢献を配分しますので、ルールベースのように被説明変数の値を直接各媒体に振り分けてはいません。
- Q：メディアの貢献度を測る方法がいくつかありましたが、どの方法が良いかを何かの指標で評価することはできるのでしょうか？あくまで結果を見て解釈し、納得度が高いものを採用するような形でしょうか。
 A：ルールベースでは配分方法は完全に恣意的に決定されますので、どの方法がよいかは客観的に評価するのは難しいかと考えられ、データに基づいた方法が望ましいと考えられます。

Q & A



- Q：ドミナンス分析は共線性がある場合だと挙動がおかしくなるなどありますでしょうか？
A：ドミナンス分析のモチベーションのひとつは説明変数間に相関がある場合に分解を行うことです。分解対象の指標 (R^2 など) が計算できれば適用可能です。共線性が懸念でしたら正則化を行うことが考えられます。
- Q：ドミナント分析の相対的な重要度は、その差や比に意味があると考えて良いのでしょうか？
A：比や割合に注目すればよいでしょう。
- Q：アトリビューション分析でどの成分が一番きいているかわかった後のアクションとしては何がありうるのでしょうか？
A：分析結果に基づいて、売上のシミュレーションなどを行い、広告費配分などを検討することが考えられます。
- Q：アトリビューション分析でメディアの貢献度を定式化する際に、メディアの接触順序だけでなく購入からどれだけ時間的に離れていたかを考慮するようなアプローチはあるのでしょうか？
A：明示的にそのような時間的な情報を考慮した方法は確認できませんでしたが、例えばそのような情報を回帰モデルに導入することが考えられるかもしれません。
- Q：例えば目的変数への寄与が大きいカバレッジ（1 レコードが 1 ユーザだとして、各変数があるチャンネルの流入有無だとしたら、ある導線はよく踏まれる、ある動線はあまり踏まれない）の小さい変数と目的変数への寄与が小さいカバレッジの広い変数、があった場合、今回のドミナンス分析だと後者の方が寄与度が大きくなる可能性もあるのでしょうか？
A：2 つのチャンネル（1：あまり踏まれないが直接コンバージョンに繋がりがやすい、2：よく踏まれるが直接コンバージョンに繋がりにくい）あったとき、どちらの寄与度が大きくなるかというのはデータに依存すると考えられます。チャンネル 2 の寄与度が大きかったとしても、商品の認知を上げるなどといった意味で最終的な売上に大きく貢献していると解釈することもできると考えられます。